

RELATÓRIO

Data Science & Business Analytics − 13.ª Edição

Data Lake of Unstructured Data



André Garcia (31811) | Dário Sequeira (31772) | Mariana António (31635) | Rodrigo Relvas (31783)

O presente relatório visa documentar as principais etapas do trabalho final de DLUD, desenvolvido em *Azure Databricks*. Este trabalho teve como principal objetivo a importação, transformação e exploração de dados para posterior análise e visualização através de um *dashboard* criado na própria plataforma.

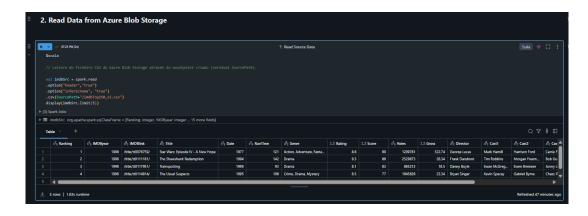
Links:

- Workspace do grupo G06
- Notebook
- Dashboard

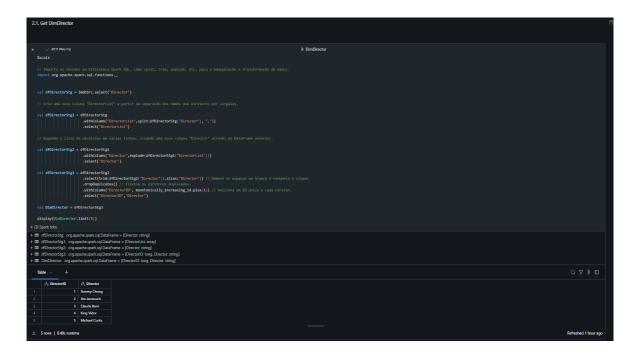
Descrevem-se, em seguida, os principais passos do trabalho, acompanhados dos respetivos *screenshots* do código:

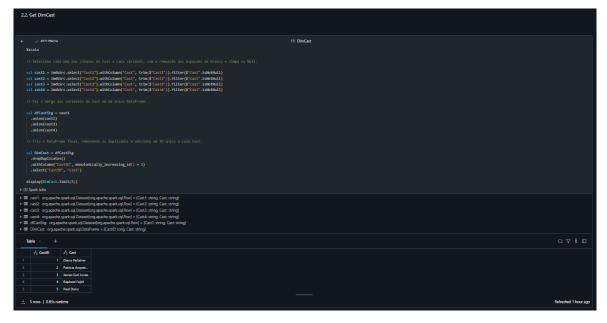
1. Começámos por criar um MountPoint (g06_sources) para estabelecer a ligação entre o Databricks e o *Storage Container* no *Azure Data Lake Storage* (ADLS). Definimos os parâmetros base e validámos que o MountPoint estava operacional;

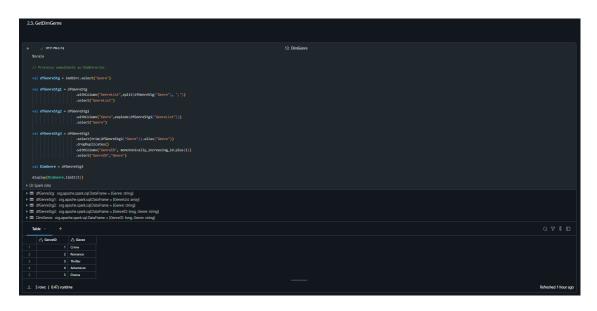
2. De seguida, lemos o ficheiro base do trabalho ('DLUD_imdbTop250_v2.csv'), previamente carregado no *Data Lake Storage Container* ('g06dlud');



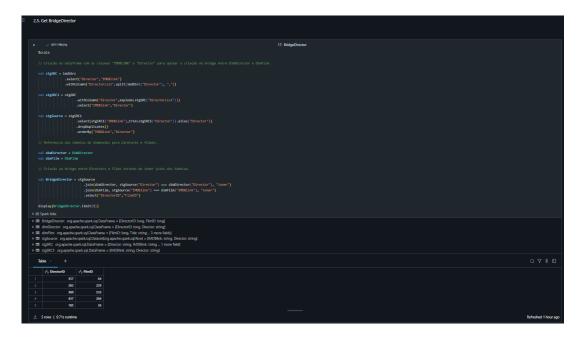
3. Criámos as 9 tabelas do modelo de dados (4 Dimensions Tables, 2 Fact Tables e 3 Bridge Tables);

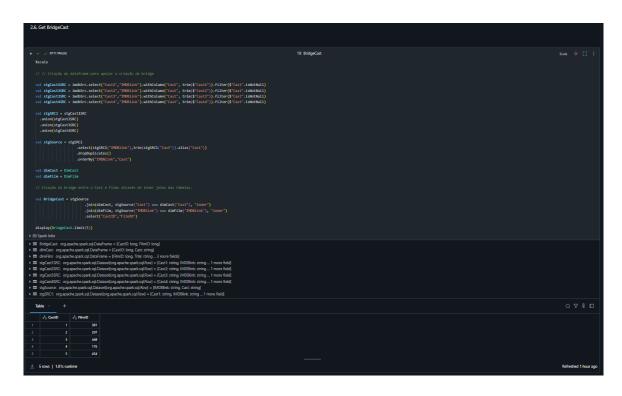


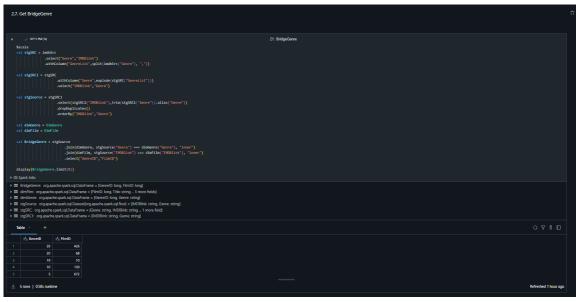


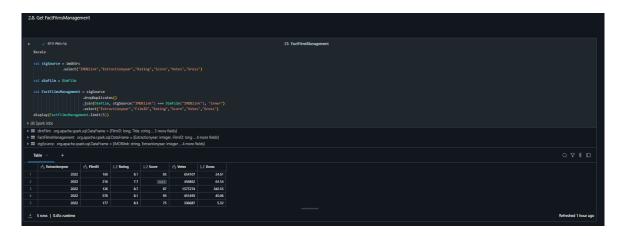


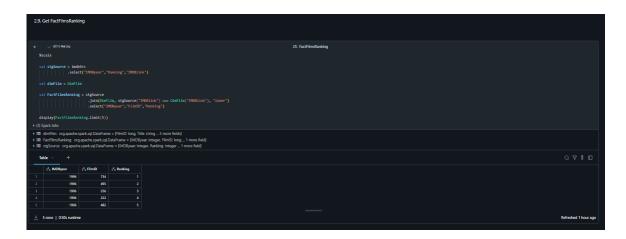




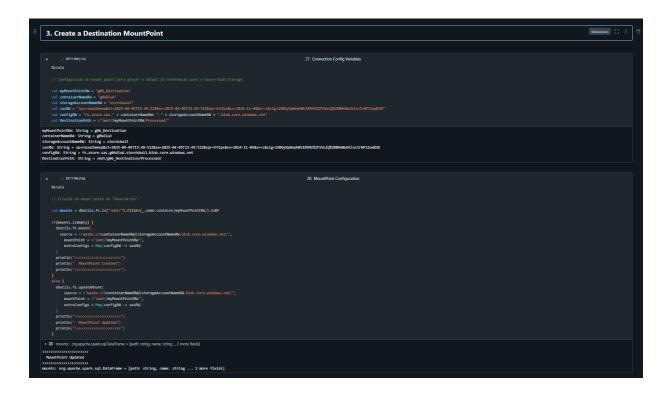




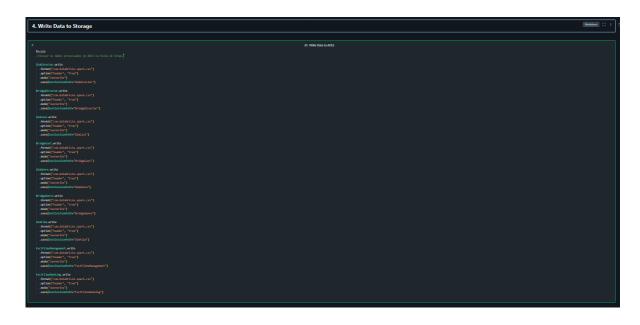




4. Criámos um MountPoint de destino para o *Storage Container*, destinado a guardar os dados processados anteriormente;



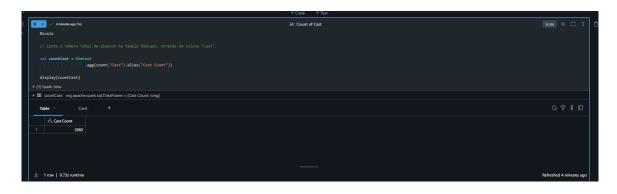
5. Gravámos os dados processados na pasta 'Processed' no ADLS através do MountPoint criado no passo anterior;

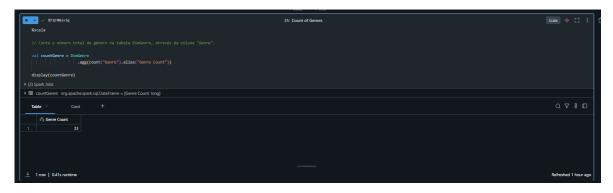


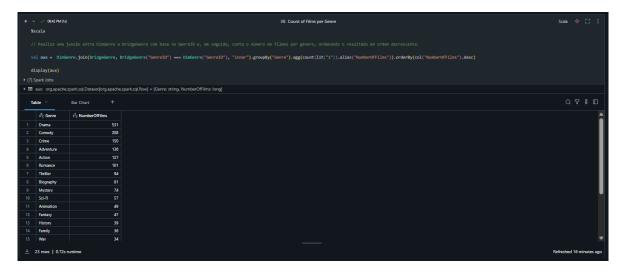
6. Realizámos diversas análises para explorar os dados, complementando com visualizações para facilitar a compreensão dos resultados e destacar *insights* relevantes;

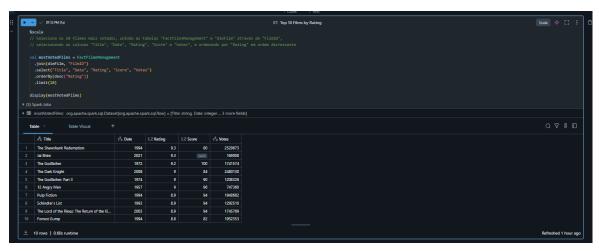


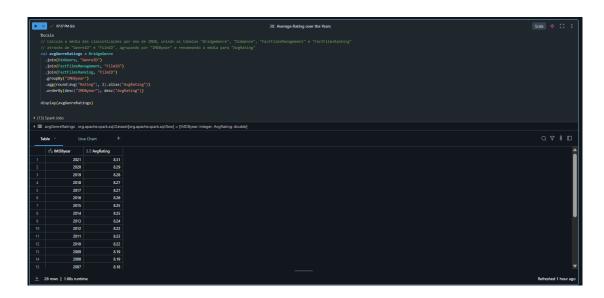


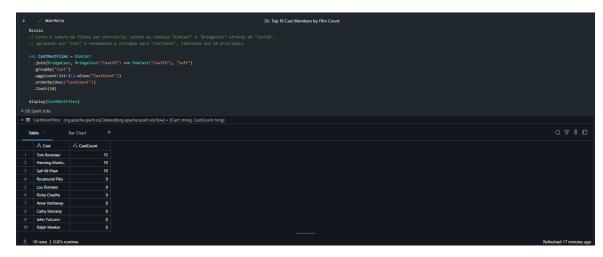


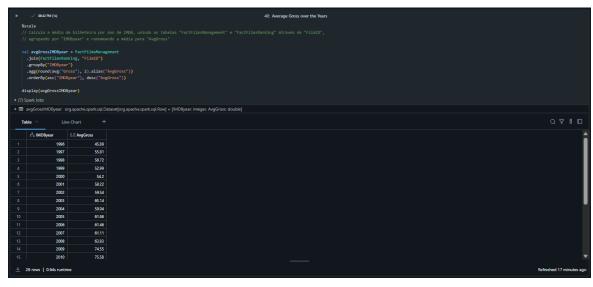


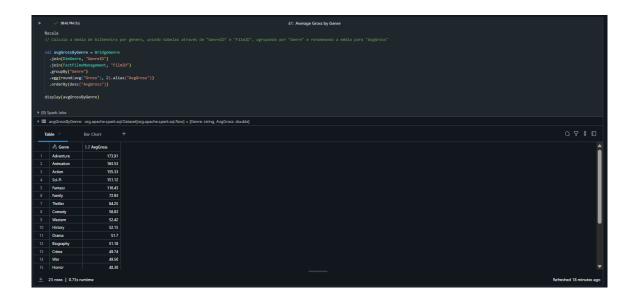












7. Por fim, incluímos as análises que considerámos mais relevantes no *Dashboard* ('G06_DLUD13_Dashboard'), utilizando gráficos e tabelas para apresentar os principais resultados de forma clara e intuitiva.

